

Feuille de route

v4 — Pivot vers FormaBot (ADN Potentiel) · mis à jour le 29 May 2026

Projet : FormaBot — assistant conversationnel de recommandation de formations pour les dirigeants TPE BTP, développé pour **ADN Potentiel** (cabinet de formation, conseil et coaching). Problématique inchangée (NLP robuste, multilingue, conforme).

Synthèse du nouveau plan

Pivot décidé le 29 mai : passage du domaine anime au domaine formation/coaching BTP TPE. L'architecture technique reste identique (SVM + TF-IDF + fuzzy + conformité). Le travail déjà fait sur la conformité (J1) est réutilisable tel quel. Le surcoût pivot (~4.5 jours) est absorbé en compressant les sprints non-critiques.

Date	Echeance
Dim. 15 juin	V1 du PDF + ZIP livrables — objectif interne (avant soutenance blanche)
Fin juin	Soutenance blanche (date exacte à confirmer)
Mar. 1er juillet 23h59	Remise officielle via Teams

Point après décision de pivot (29 mai)

- **Architecture technique** : 100% réutilisable (SVM + TF-IDF + fuzzy + mémoire + conformité).
- **J1 déjà livré** : disclosure bot + export RGPD (texte à reformuler pour FormaBot, structure inchangée).
- **Corpus prêt** : 223 phrases d'entraînement sur 19 intentions formation (formations_training_corpus.csv).
- **Test set prêt** : 91 phrases indépendantes (evaluation/test_set_formation.csv).
- **Squelette mémoire** ajusté pour ADN Potentiel et marché formation BTP TPE.
- **En attente** : ton export CSV du catalogue ADN Potentiel pour basculer l'app.

Phase 1 — Code et livrables techniques (J1 à J11)

J1 · Ven. 29 mai	[FAIT] Conformite 1/2 : disclosure bot + export RGD	CODE	~3-4h
J2 · Sam. 30 mai	Conformite 2/2 : delete all + page Model Card	CODE	~4-5h

Plus une mise à jour du texte du bandeau disclosure pour mentionner FormaBot et ADN Potentiel au lieu d'AnimeBot.

J3 · Dim. 31 mai	[PIVOT] Migration SQLite + integration vrai catalogue ADN	CODE	~5-6h
-------------------------	--	-------------	-------

Fichier de travail : app_formabot.py (le projet AniReco app.py reste intact). Dès reception de ton vrai formations_adn.csv : (1) remplacement du placeholder de 17 lignes, (2) création du schema SQL formations avec indexes, (3) génération du dump formabot.sql, (4) adaptation de load_resources() pour charger depuis SQLite plutôt que CSV.

J4 · Lun. 1er juin	[PIVOT] Test & tuning du classifieur sur le vrai catalogue	CODE	~4-5h
---------------------------	---	-------------	-------

Note : la structure d'app_formabot.py est déjà prête (load depuis formations_training_corpus.csv, 19 intentions implémentées : recommend_by_theme, list_by_theme, search_by_format/duration/audience/certification, ask_info/price/duration/format/objectives, etc.). Ce jour : enrichir le corpus d'entrainement si certains intents ont une confiance faible sur les vraies requêtes, ajuster les overrides regex, tester avec des dirigeants TPE BTP si possible.

J5 · Mar. 2 juin	Robustesse au bruit + nouvelle evaluation comparative	CODE	~4h
-------------------------	--	-------------	-----

Générateur de variantes bruitées du test set formation. Run complet : 4 baselines sklearn sur le nouveau corpus + matrice de confusion + plot F1/latence. Mise a jour du rapport d'evaluation.

J6 · Mer. 3 juin	Accessibilite RGAA / WCAG 2.1 AA	CODE	~3-4h
J7 · Jeu. 4 juin	DistilBERT en local + integration au rapport	CODE	~2-3h
J8 · Ven. 5 juin	Deploiement Streamlit Cloud + URL publique	CODE	~3-4h

Dépôt GitHub public, lien Streamlit Cloud, secrets, vérification de l'URL publique. **Bloquant** — exigé par le guide.

J9 · Sam. 6 juin	README/PDR + tableau probleamtiques + freeze code	CODE	~3-4h
J10 · Dim. 7 juin	Buffer technique + ajustements finaux	CODE	~0-4h
J11 · Lun. 8 juin	Buffer / debut redaction si avance	CODE	~0-4h

Phase 2 — Rédaction V1 du mémoire (J12 à J18)

Cible : **50 pages** hors annexes. Structure détaillée dans *squelette_memoire.md* (mis à jour pour ADN Potentiel). Format : Times New Roman 12 / Arial 11 / Calibri 12, marges 2.5 cm, interligne 1.5 max, pages numérotées. Fichier final : MBOGA_GLENN_THESE.pdf.

J12 · Mar. 9 juin	[PIVOT] Page presentation + Descriptif ADN Potentiel (entreprise réelle)	REDAC TION	~~5 pages
--------------------------	---	-----------------------	--------------

Storytelling ADN, valeurs, missions, environnement éco/techno/données. **Avantage du pivot** : tout est réel, plus de cadre fictif à justifier.

J13 · Mer. 10 juin	[PIVOT] Etude marche + concurrents (CCCA-BTP, CAPEB, Bpifrance)	REDAC TION	~~6 pages
---------------------------	--	-----------------------	--------------

Sources INSEE / Centre Inffo / FFB pour les chiffres marche formation BTP TPE. 3 concurrents minimum, même trame pour chacun (PAS en tableau).

J14 · Jeu. 11 juin	Problematique + Gestion de projet (Gantt, budget, veille, risques, charte)	REDAC TION	~~12 pages
J15 · Ven. 12 juin	Exploitation des donnees (sources, dictionnaire, manipulation, ML)	REDAC TION	~~13 pages
J16 · Sam. 13 juin	Developpement app + conformite + accessibilite	REDAC TION	~~9 pages
J17 · Dim. 14 juin	Conclusion + abstract + biblio + table matieres + mise en page	REDAC TION	~~5 pages
J18 · Lun. 15 juin	Generation PDF V1 + assemblage ZIP — livrable soutenance blanche	REDAC TION	~~

Phase 3 — Polish + prépa soutenance blanche (16 à 28 juin)

- **Support de présentation** MBOGA_GLENN_PREZ.pdf — 30 min, ~25-30 diapos.
- **Répétition orale chronométrée** — viser 28 min pour marge.
- **Préparation jeu de rôle 30 min** — scénarios client, questions/objections sur le contexte ADN/BTP.
- **Soutenance blanche** — prendre les retours du jury.
- **Ajustements mémoire** selon retours.
- **Complétion bibliographie** (cible 25-30 références).

Phase 4 — Finalisation et remise (29 juin au 1er juillet)

- Corrections finales suite soutenance blanche.
- Génération finale PDF + ZIP.
- Vérification compatibilité multi-navigateurs.
- Remise sur Teams le **1er juillet avant 23h59**.

Ce qui reste coupe

- **Recherche sémantique** (sentence-transformers sur descriptions de formations) — perspective dans la conclusion.
- **Docker** — Streamlit Cloud suffit.
- **Tableau de bord d'usage** — perspective.

- **Multi-langue au-delà FR/EN** — perspective.
- **Intégration CRM ADN Potentiel** — perspective d'industrialisation post-soutenance.

En attente de ta part (URGENT pour J3)

- **Export CSV du catalogue ADN Potentiel** — fichier formations_adn.csv dans le dossier memoire, avec les colonnes définies dans le schema partage en chat.
- Sans ce fichier le J3 ne peut pas démarrer — prévoir donc de le produire d'ici samedi 30 mai au plus tard.
- Si certaines colonnes sont indisponibles, indique-le explicitement — on adaptera (placeholder, ou retrait de l'attribut concerné).