

Entretien de suivi de mémoire

M2 Nexa · pipeline NLP / assistant conversationnel anime · brief du 11 May 2026

Problématique du mémoire : pipeline NLP capable de comprendre des requêtes multilingues, bruitées et hétérogènes dans un contexte métier, tout en garantissant performance, explicabilité, conformité réglementaire et intégration fluide dans une application web.

1. État d'avancement global

Le prototype est fonctionnel et intègre désormais une couche d'évaluation rigoureuse. Voici les indicateurs clés.

Corpus d'entrainement	210 phrases · 15 intentions · FR + EN
Jeu de test indépendant	86 phrases · 0 chevauchement avec le training
Dataset métier	4 985 animes · 32 colonnes · titres trilingues
Modèle en production	SVM + TF-IDF (calibré) · rapidfuzz pour titres
Performance (F1 macro test)	0.637 — meilleur des 4 baselines testées
Latence p95	23.6 ms — viable interactif
Stockage des conversations	100% local, JSON, aucun envoi externe

2. Nouveautés depuis la dernière session

2.1 Évaluation rigoureuse (sprint 1-2 terminé)

C'était le point faible identifié précédemment. Aujourd'hui :

- Constitution d'un **jeu de test indépendant** de 86 phrases annotées a la main, distinct du training set (vérifié après normalisation).
- Comparaison de **4 modèles baseline** sklearn (SVM, Naive Bayes, Logistic Regression, Random Forest) sur ce test set.
- **K-fold cross-validation stratifiée** (k=3) sur le corpus d'entrainement avec intervalles de confiance.
- **Benchmark de latence** par modèle sur 100 prédictions unitaires.
- Code prêt pour **DistilBERT multilingue** (run_distilbert.py), à exécuter en local (~5 min CPU) faute de bande passante en sandbox.
- Production de matrices de confusion par modèle et d'un graphe *F1 vs latence* intégrables au mémoire.

Résultats principaux (test set indépendant) :

Modele	F1 macro (test)	F1 (CV 3-fold)	Latence p95
SVM + TF-IDF (prod.)	0.637	0.479 +/- 0.036	23.6 ms
Random Forest	0.495	0.435 +/- 0.039	243.9 ms
Logistic Regression	0.354	0.214 +/- 0.045	4.3 ms
Naive Bayes	0.175	0.100 +/- 0.005	3.5 ms

Le SVM domine sur les *deux* axes simultanément. Le Random Forest atteint un F1 décent mais avec une latence x10 prohibitive. C'est l'argument structurant du chapitre « choix d'architecture » du mémoire.

2.2 Migration vers un dataset crédible

- Passage d'un échantillon de 10 animes à un dataset MAL de **4 985 animes** (animes_2026.csv).

- Adaptation du code : renommage de colonnes, parsing des champs structurés (genres / tags / synonymes en pipe-separated), gestion des NaN.
- Index de recherche **multilingue** sur les titres : l'utilisateur peut taper « Shingeki no Kyojin », « Attack on Titan » ou un synonyme, tout matche.
- Couverture des genres passée de 12 à **21**.

2.3 Nouvelles intentions et logique métier

- Passage de 10 à **15 intentions** : ajout de list_top, list_by_genre, ask_available_genres, thanks, help.
- **Top N paramétré** et filtré par genre « top 5 anime de sport » renvoie le bon Top 5 du bon genre.
- **Override symbolique** du classifieur sur les patterns sans ambiguïté (regex « top N ») — filet de sécurité contre les mauvaises classifications, argument pour l'architecture hybride.
- **Anti-répétition** des recommandations dans une même session (mémoire conversationnelle).

2.4 Performance et UX

- **Skip conditionnel de l'extraction fuzzy de titre** : gain x100+ sur les requêtes type « top N » (auparavant : >45s d'attente, aujourd'hui : instantané).
- Backend **rapidfuzz** (10-100x plus rapide que fuzzywuzzy) avec fallback.
- **Historique persistant** des conversations en JSON local + bouton nouvelle conversation / suppression / rechargement.
- Détection automatique **FR/EN** via langdetect à chaque tour.

3. Limites identifiées (à assumer en soutenance)

- Classes minoritaires faibles : **fallback** et **goodbye** ont un F1 de 0 sur le test — le modèle ne sait pas « ne pas répondre ».
- Aucun intégration d'**approche sémantique** aujourd'hui : la recherche par thématique (« anime sur des robots géants ») n'est pas couverte.
- L'axe **conformité réglementaire** de la problématique manque encore d'implémentation visible dans l'UI (RGPD, AI Act).
- Le système ne parle que FR et EN ; pas d'autres langues malgré le support technique de langdetect.
- La cross-validation 3-fold est limitée : idéalement k=5, mais coût calcul important sur 210 phrases.

4. Perspectives — roadmap des 5 prochaines semaines

Document détaillé dans *feuille de route.pdf*. Synthèse ci-dessous, dans l'ordre où j'ai prévu d'attaquer :

Sem.	Thème	Apport principal au mémoire
3	Robustesse au bruit (typos, accents, casse, mots parasites)	Mesure quantifiée de la dégradation F1 sur variantes bruitées
4	Recherche sémantique (sentence-transformers, embeddings)	Argument architecture hybride symbolique + neurale
5	Nouvelles intentions sur dataset enrichi (studio, année, score, tag, source)	Exploitation des 32 colonnes : passe de 5 dimensions de recherche à 10
6	Conformité réglementaire (RGPD art. 17/20 + AI Act art. 50, model card)	Section ~15 pages aujourd'hui inexistante, alignement explicite problématique
7	Déploiement Streamlit Cloud + tableau de bord d'usage	URL publique pour la soutenance, observabilité

Ce que je ne prévois pas de faire d'ici fin juin (et pourquoi) :

- **Fine-tuner un transformer** sur 210 exemples : surapprentissage assuré, aucun gain mesurable.
- **Intégrer un LLM génératif** pour les réponses : contredit l'axe « explicabilité » et ajoute une dépendance externe.
- **Réécrire en API + frontend** : gain pédagogique faible vs coût en temps.

5. Questions à aborder pendant l'entretien

Points sur lesquels j'aimerais l'avis et les arbitrages du directeur de mémoire :

- **Format de la soutenance** : durée, support attendu, démo live possible ou pas ?
- **Délégation de l'équilibre des axes** : faut-il privilégier un pilier de la problématique (performance, conformité, hétérogénéité) ou rester sur une couverture équilibrée ?
- **Références bibliographiques** : lectures clés à citer sur l'intent classification, l'évaluation NLP, l'AI Act ?
- **DistilBERT** : cette comparaison est-elle suffisante ou attendez-vous d'autres baselines (XLM-R, mBERT, sentence-transformers seul) ?
- **Conformité réglementaire** : avez-vous un exemple de model card ou un cas d'analyse RGPD que je peux prendre comme référence ?
- **Déploiement** : une URL publique en soutenance est-elle attendue ou simplement « nice to have » ?
- **Plan B** : si je dois couper, validée l'ordre de priorité (couper déploiement, puis nouvelles intentions, puis recherche sémantique en dernier) ?

6. Documents associés

- **feuille de route.pdf** : roadmap détaillée 7 semaines, livrables par sprint.
- **evaluation/EVALUATION_REPORT.md** : rapport complet de l'évaluation (méthodologie + résultats + discussion).
- **evaluation/results/** : matrices de confusion, tableaux comparatifs, plot F1 vs latence.
- **app.py** : code de l'application Streamlit, 1 000+ lignes, fonctionnel.